

# Q-Learning ile Akıllı Ofis Klima Kontrolü

Elif Yılmaz - 25435004004

## Özet

Bu çalışmada, ofis iklimlendirme sisteminde enerji verimliliği ve insan konforunu aynı anda en üst düzeye çıkarmak amacıyla Q-Learning tabanlı bir yapay zekâ ajanı geliştirilmiştir. 100.000 episodluk eğitim sonucunda ajan, çalışma saatlerinde %94.4 konfor başarısı elde ederken, günlük enerji tüketimini yalnızca **6.7 kW** seviyesine indirmiştir. Geliştirilen sistem, "ön soğutma" ve "serbest salım" gibi ileri düzey stratejileri tamamen otomatik olarak öğrenmiştir.

## 1 Giriş

Binalar küresel enerji tüketiminin yaklaşık %40'ından sorumludur ve bu oranın büyük kısmı HVAC sistemlerinden kaynaklanmaktadır. Geleneksel termostat kontrollü sistemler yalnızca anlık sıcaklığa tepki verdiğiinden, hem konfor kaybına hem de yüksek enerji israfına yol açmaktadır.

Bu projede, dış sıcaklık ve günüün zaman dilimini dikkate alarak **proaktif** ve **enerji verimli** kararlar verebilen bir reinforcement learning ajanı tasarlanmıştır.

## 2 Yöntem ve Ortam Tasarımı

OpenAI Gymnasium kütüphanesi kullanılarak `SmartOfficeEnv` adında özel bir simülasyon ortamı geliştirilmiştir.

### 2.1 Durum Uzayı (State Space)

- İç sıcaklık: 13 seviye (15–30°C)
- Dış sıcaklık: 11 seviye (-5–40°C)
- Zaman dilimi: 4 periyot (Gece, Hazırlık, Mesai, Akşam)

Toplam durum sayısı:  $13 \times 11 \times 5 = 715$

### 2.2 Aksiyon Uzayı (Action Space)

7 ayrık aksiyon: Kapalı (0), 3 kademe soğutma (1-3), 3 kademe ısıtma (4-6)

## 2.3 Ödül Fonksiyonu (Reward Function)

Çok katı bir ödül sistemi uygulanmıştır:

- Mesai saatinde konfor bandında ( $22\text{--}24^{\circ}\text{C}$ ) ve kapalı  $\rightarrow +100$
- Öğlen kalkan koruması ihlali ( $>22.8^{\circ}\text{C}$ 'de kapatma)  $\rightarrow -500$
- Gece/akşam aktif kullanım  $\rightarrow -200$
- Konfor dışı + kapatma  $\rightarrow$  ekstra  $-300$

## 3 Algoritma: Q-Learning

Q-değerleri Bellman denklemi ile güncellenmiştir:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)] \quad (1)$$

$\alpha = 0.1$ ,  $\gamma = 0.99$ , 100.000 episod eğitim ( 1.2 dakika).

## 4 Deneysel Sonuçlar ve Değerlendirme

Metrik	Rastgele Ajan	Eğitilmiş Ajan
Çalışma saati konfor oranı	%11.1	<b>%94.4</b>
Günlük enerji tüketimi (kW)	22.5	<b>6.7</b>
Ortalama toplam ödül	-4814	<b>+995</b>

Tablo 1: Rastgele vs. Eğitilmiş Ajan Karşılaştırması

### 4.1 Geliştirilen Stratejiler

1. **Ön soğutma:** Sabah 06:00'da düşük-orta soğutma ile mesai başlangıcında  $23^{\circ}\text{C}$  sağlanmıştır.
2. **Serbest salınım:** En sıcak saatlerde (12:00–13:00) klima kapatılmış, enerji tasarrufu yapılmıştır.
3. **Hızlı düzeltme:** 14:00 civarı konfor sınırı aşıldığında anında müdahale edilmiştir.

## 5 Sonuç

Geliştirilen Q-Learning ajanı, oldukça katı ceza-reward yapısına sahip bu ortamda:

- %94.4 çalışma saati konfor başarısı
- Günlük yalnızca 6.7 kW enerji tüketimi

elde ederek, klasik kontrol sistemlerine göre hem daha konforlu hem de çok daha verimli bir çözüm sunmuştur.

Bu sonuçlar, reinforcement learning'in gerçek bina otomasyon sistemlerinde başarıyla uygulanabileceğini güçlü bir şekilde kanıtlamaktadır.