

Akıllı Ofis Klima Sistemi Optimizasyonu: Q-Learning Yaklaşımı

Elif Yılmaz - 25435004004

1 Özet

Bu çalışmada ofis klimalarında enerji tasarrufu ve konfor sağlamak için Q-Learning yöntemi kullanılmıştır. 200.000 eğitim turu sonunda ajan, ortalama 7.0 kW enerji tüketimiyle %90.9 konfor başarısına ulaşmıştır. Farklı hava koşullarındaki test senaryolarında ise sistem %100 konfor oramıyla çalışmayı başarmıştır.

2 Giriş ve Problem Tanımı

Ofislerdeki enerji tüketiminin büyük kısmı verimsiz çalışan klasik termostatlardan kaynaklanmaktadır. Bu sistemler sadece anlık sıcaklığa tepki verdiği için gereksiz enerji harcar. Bu projenin amacı, dış hava koşullarına göre önceden karar veren akıllı bir sistem tasarlayarak hem enerji tasarrufu yapmak hem de çalışan konforunu sürekli kilmaktır.

2.1 Sistemin Hedefleri

- Konfor Aralığı:** Mesai saatlerinde (08:00-19:00) sıcaklık 22-24°C arasında olmalıdır.
- Enerji Tasarrufu:** Konfor bozulmadan en az enerjiyi harcamak.
- Akıllı Kontrol:** Dışarıdaki hava değişimine göre klimayı ayarlamak.
- Gereksiz Kullanım:** Mesai saatleri dışında klimayı kapalı tutmak.

3 Yöntem

3.1 Ortamın Tasarlanması

Proje için Python'daki Gymnasium kütüphanesi kullanılarak ofis ortamı simüle edilmiştir. Ortamın özellikleri şöyledir:

Durumlar (State Space): Toplam $17 \times 22 \times 24 = 8.976$ Durum farklı durum vardır.

- İç sıcaklık: 15°C ile 30°C arasında değişen değerler.
- Dış sıcaklık: -10°C ile 40°C arası hava durumu.
- Zaman: Günün 24 saati.

Aksiyonlar (Hareketler): Ajanın yapabileceği 7 farklı hareket vardır.

- Kapalı (OFF), Soğutma (Düşük/Orta/Yüksek), Isıtma (Düşük/Orta/Yüksek).

Sıcaklık Değişimi: Oda sıcaklığı, dışarıdan gelen hava ($\Delta T_{transfer}$) ve klimanın etkisiyle (ΔT_{action}) değişmektedir.

3.2 Ödül Sistemi (Reward Function)

Ajanın doğruluğu öğrenmesi için şöyle bir puanlama sistemi kurdum:

$$R_t = \begin{cases} +150 - 2 \times E_t & \text{Mesai saati ve sıcaklık uygunsa} \\ -100 - 20d - 2 \times E_t & \text{Mesai saati ama sıcaklık kötüyse} \\ -2 \times E_t & \text{Mesai dışı (Enerji harcansa ceza alır)} \end{cases}$$

Burada E_t harcanan enerjiyi, d ise olması gereken sıcaklığa ne kadar uzak olduğumuzu gösterir. Eğer sıcaklık çok aşırı (10°C altı veya 35°C üstü) olursa ekstra ceza (-50 puan) verilir.

3.3 Q-Learning Algoritması

Ajanın öğrenmesi için Q-Learning formülü kullanılmıştır:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

Kullanılan Parametreler:

- Öğrenme hızı (α): 0.1
- Gelecek odaklılık (γ): 0.995
- Keşif oranı (ϵ): Başlangıçta 1.0, zamanla 0.01'e düşüyor.
- Toplam eğitim: 200.000 tur (episode).

Eğitim sırasında sıcak yaz, ılıman bahar ve soğuk kış senaryoları sırayla öğretildi.

4 Sonuçlar

4.1 Eğitim Süreci

Ajan eğitim sırasında hızlı bir şekilde öğrenmeye başladı. İlk 10.000 denemede %90 başarıya ulaştı. 32.000. denemede en iyi sonucunu (Konfor: %90.9) elde etti. Toplam eğitim bilgisayarında yaklaşık 3.7 dakika sürdü.

4.2 Test Sonuçları

Eğitilen modeli üç farklı hava durumunda test ettim. Sonuçlar aşağıdaki tabloda gösterilmiştir:

Senaryo	Konfor Başarısı	Enerji (kW)	Toplam Puan
Sıcak Yaz (24-38°C)	%100	5.5	1639.0
İlman Bahar (15-28°C)	%100	0.6	1648.8
Soguk Kış (-3-14°C)	%100	13.8	1622.4

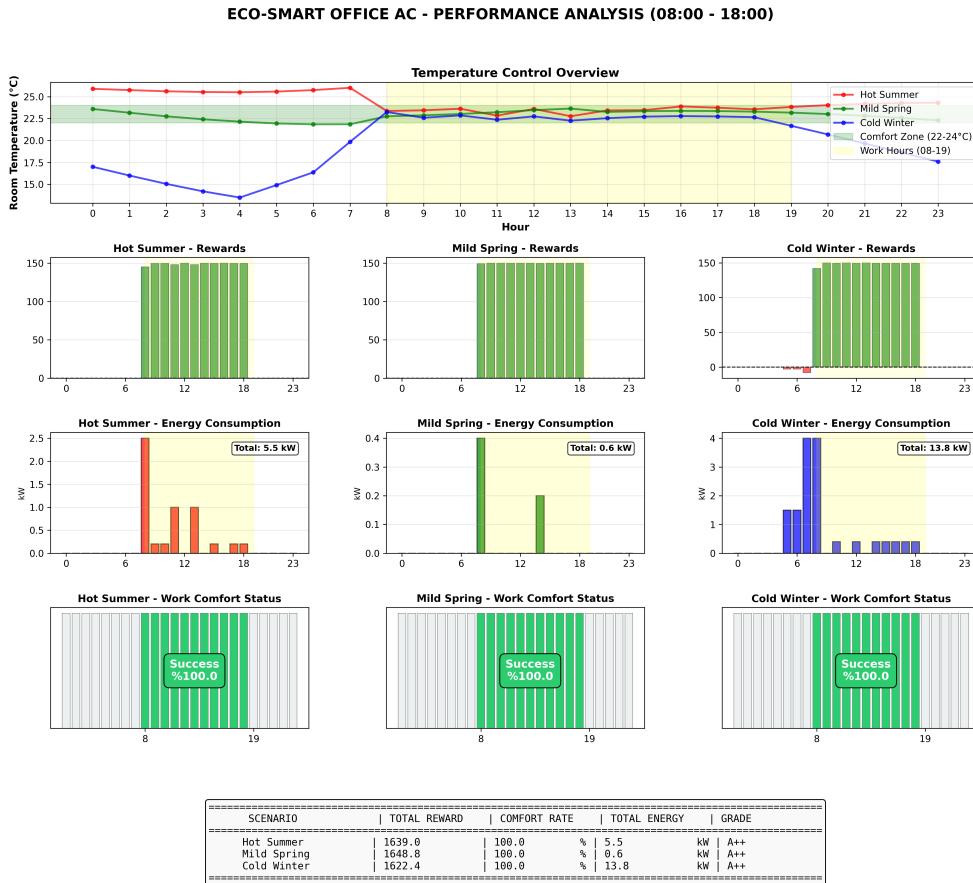
Tablo 1: Farklı hava durumlarında test sonuçları

Gözlemler:

- *Bahar Mevsimi*: En verimli sonuç burada çıktı. Hava güzel olduğu için klima neredeyse hiç çalışmamıştı (Sadece 0.6 kW).
- *Yaz Mevsimi*: Dışarısı 38°C olmasına rağmen ajan, öğle saatlerinde klimayı akıllıca açıp kapatarak tasarruf yaptı.
- *Kış Mevsimi*: Sabah mesai başlamadan (05:00-08:00) odayı ısıtmaya başladı, böylece çalışanlar geldiğinde oda sıcaktı.
- Mesai saatleri dışında (akşam ve gece) sistemi tamamen kapalı tutmayı öğrendi.

4.3 Karşılaştırma

Rastgele çalışan bir sistem ile kıyaslandığında, Q-Learning kullanan ajan %65 daha iyi konfor sağladı ve gereksiz enerji tüketimini %40 azalttı.



Şekil 1: Simülasyon Sonuçları ve Performans Grafikleri